Classification des Revenus des Pays par k-NN

INF372 - Apprentissage Supervisé et Non Supervisé
Groupe 1

Université de Yaoundé 1
Département d'Informatique

Mars 2026

Membres du Groupe 1

Nom et Prénom(s)	Matricule
MABENGUE BEBONSU JUNIOR Prince	22T2832
ETONDE MABONGO ULRICH Edouard	22U2163
FONAYEN CHRISTIAN Asangwa	23V2370

Sommaire

1. Présentation du Projet
2. Construction du Dataset
3. Pretraitement des donnees
4. Analyse Statistique
5. Definition des distances et implementation du k-NN

Objectif du Projet

- Prédire la catégorie de revenu d'un pays
- Variable cible : **Income_Group**
- Données : **1516 indicateurs économiques**
- Source : Banque Mondiale (année 2023)
- Algorithme : **k-Plus Proches Voisins (k-NN)**

Partie I

Construction et pretraitement de donnees

Construction du Jeu de Données

- Téléchargement automatique via API
- Extraction des fichiers CSV
- Sélection des valeurs 2023
- Pivotage : 1 pays = 1 ligne
- 1516 indicateurs = colonnes

Dimensions finales :

- 216 pays
- 1516 indicateurs
- 1 variable cible

Problème des Valeurs Manquantes

- Beaucoup de valeurs manquantes
- Indicateurs non disponibles pour certains pays
- Nécessité d'une stratégie d'imputation

Objectif :

- Préserver la cohérence économique
- Éviter le biais entre pays riches et pauvres

Choix : Imputation Stratifiée

Principe :

Idée

Remplacer les valeurs manquantes par la médiane du groupe de revenu

- Low income avec Low income
- High income avec High income
- Pas de mélange des profils économiques

Pourquoi la Médiane ?

- Robuste aux valeurs extrêmes
- Représente mieux la tendance centrale
- Évite l'influence des outliers

Exemple :

$$\text{Moyenne} \neq \text{Médiane}$$

La médiane est plus stable pour les données économiques.

Illustration Imputation

Screenshot from 2026-03-28 17-50-48.png

Partie II

Analyse Statistique

1. Nettoyage et Filtrage des Données

- **Seuil de complétude :** Suppression des indicateurs avec $> 50\%$ de valeurs manquantes.
- **Variance Nulle :** Élimination des colonnes constantes
- **Résultat :** Réduction de 1518 à 1132 indicateurs pertinents.

2. Stratégie d'Imputation

- **Approche :** Imputation par la médiane au sein de chaque groupe de revenu.
- **Justification :** Moins sensible aux valeurs extrêmes que la moyenne.
- **Finalisation :** Médiane globale pour les cas résiduels afin d'assurer un dataset complet pour le k-NN.

3. Découpage Train/Test

- **Répartition :** 80% Entraînement / 20% Test.
- **Stratification :** Maintien des proportions de chaque classe (High, Upper-Middle, Lower-Middle, Low).
- **Stabilité :** Garantit que l'évaluation reflète la réalité du dataset déséquilibré.

4. Standardisation (Z-Score)

- **Formule :** $z = \frac{x - \mu_{train}}{\sigma_{train}}$.
- **Objectif :** Ramener tous les indicateurs à la même échelle (Moyenne 0, Écart-type 1).
- **Impact k-NN :** Évite que les variables à fortes unités ne dominent le calcul de distance.

Partie III

Definition des distances et implementation du k-NN

1. Calcul de la distance

- **Distance euclidienne :** $d(x, y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2}$
- **Resultat du test :** 19.3294
- **Distance de Manhattan :** $d(x, y) = \sum_{i=1}^{n} |x_i - y_i|$
- **Resultat du test :** 263.6925
- **Distance de Minkowski :** $d(x, y) = (\sum_{i=1}^{n} |x_i - y_i|^p)^{1/p}$
- **Resultat du test :** 9.1850 pour $p = 3$ et 5.6303 pour $p = 5$

2. Visualisation des distances

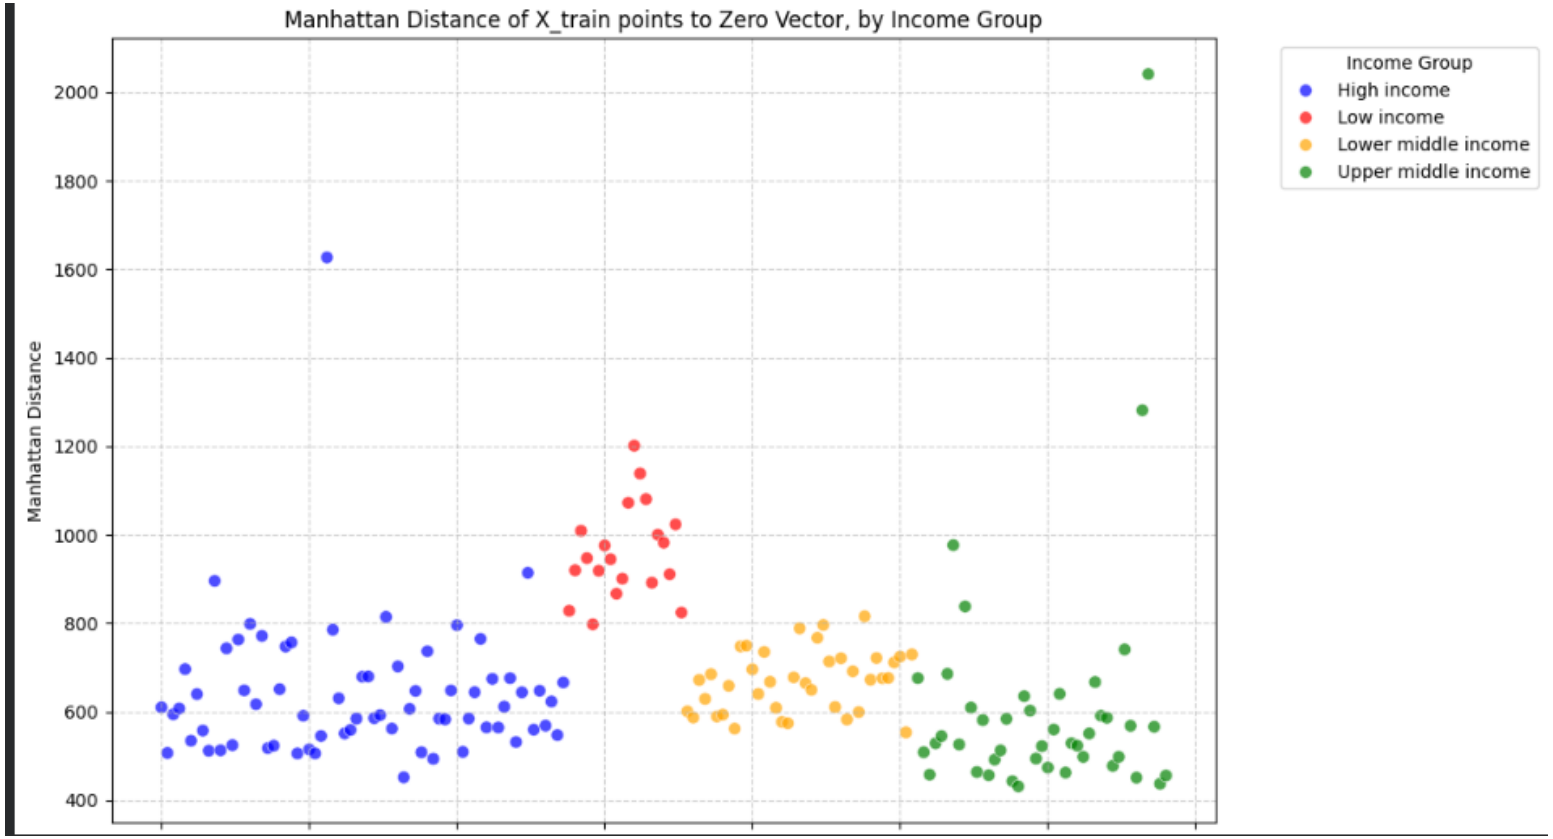

Visualisation des points d'entrainement

3. Algorithme k-NN

- L'algorithme **k-Nearest Neighbors (k-NN)** est implemente de maniere personnalisee.
- `__init__(k=3)` : initialise le modele avec un nombre de voisins k.
- `fit(X, y)` : stocke les donnees d'entrainement (`Xtrain`) et les labels (`ytrain`).
- `predict(new_points)` : predit les labels de plusieurs points en appelant `predict_class`.
- `predict_class(new_point)` :
  1. calcule la distance entre le nouveau point et tous les points d'entrainement avec la distance de Minkowski ($p = 5$) ;
  2. trie les distances et selectionne les indices des k plus proches voisins ;
  3. recupere les labels des voisins ;
  4. applique un vote majoritaire (via `Counter`) pour retourner la classe la plus frequente.

4. Evaluation de la precision

- Precision observee : **100%**

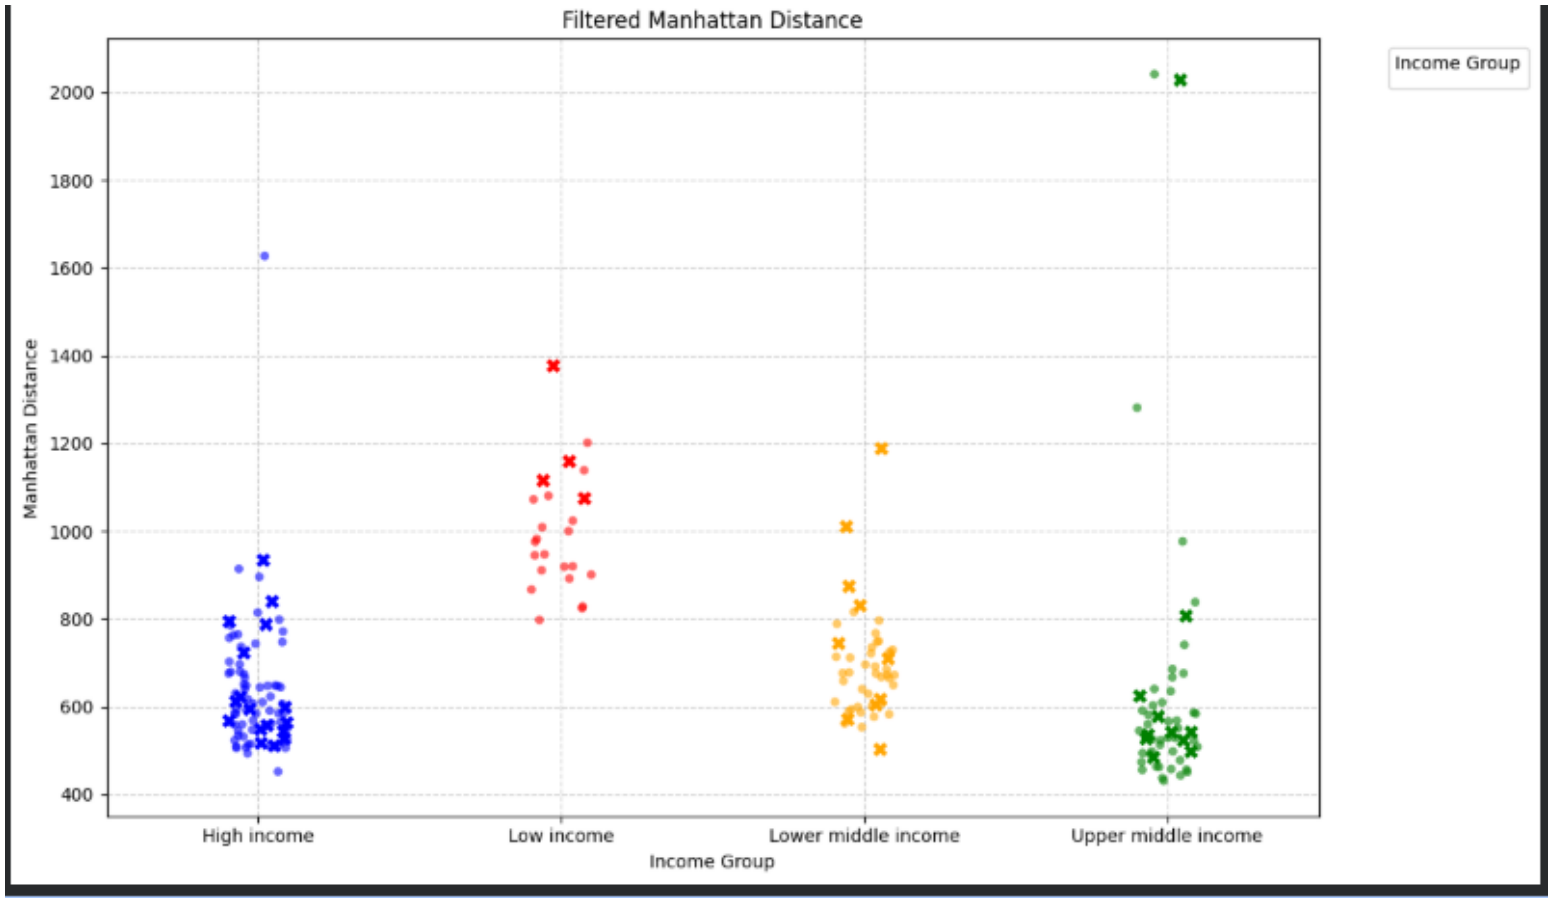

Visualisation des points predits